1. LAUFZEITSYSTEME

Source Code → Compiler → Maschinencode → Laufzeitsystem

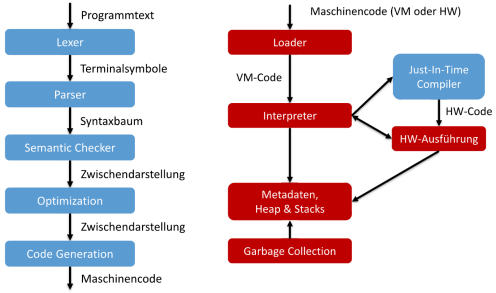

Syntax: Struktur des Programms
Semantik: Bedeutung des Programms

2. EBNF-SYNTAX

Kann ***kontextfreie Grammatiken*** *(Extended Backus-Naur Form)* darstellen.

Begriff	*Beispiel*	*Sätze*
Konkatenation	`"A" "B"`	«AB»
Alternative	`"A" | "B"`	«A» oder «B»
Option	`["A"]`	∅ oder «A»
Wiederholung	`{"A"}`	∅,"A","AA", …

Beispiel: $a * b + c$

Expression = *Term* | *Expression* `"+"` *Term*.
Term = *Variable* | *Term* `"*"` *Variable*.
Variable = `"a"` | `"b"` | `"c"` | `"d"`.

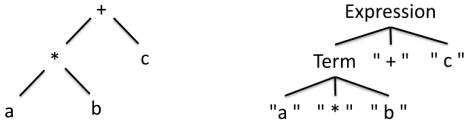

Darf nicht ***mehrdeutig*** sein: *Expression* = *Number* | *Expression* `"-"` *Expression*.
Number = `"1"` | `"2"` | `"3"`.

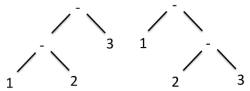

Besser: *Expression* = *Number* { `"-"` *Number* }.

3. LEXIKALISCHE ANALYSE

Input: Zeichenfolge, ***Output:*** Folge von Terminalsymbolen *(Tokens)*.
Kann ***Reguläre Sprachen*** analysieren. *(Regulär = hat rekursionsfreien EBNF oder kann in rekursionsfreien EBNF umgewandelt werden)*
Eliminiert ***Whitespaces*** und ***Kommentare***, merkt ***Positionen*** im Code.
Maximum Munch: Lexer ist greedy.
Vorteile: Abstraktion *(Parser muss sich nicht um Textzeichen kümmern)*, Einfachheit *(Parser hat nur noch Lookahead pro Symbol)*, Effizienz *(benötigt keinen Stack)*.
Hat ***one-character-lookahead***, um Typ immer bestimmen zu können.
Tokens: ***Fixe / Static Token (1)*** *(Keywords, Operatoren, Interpunktion)*, ***Identifiers (2)*** `MyClass`, ***Integer (3)*** `123`, ***Strings (4)*** `"Hello"`, ***Characters (5)*** `'a'`

```
while (i < 100) { x = x + 1; }
```

"while" *(1)*, ***"("*** *(1)*, ***"x"*** *(2)*, ***"<"*** *(1)*, ***100*** *(3)*, ***")"*** *(1)*, ***"{"*** *(1)*, ***"="*** *(1)*, ***"+"*** *(1)*, ***"1"*** *(3)*, ***";"*** *(1)*, ***"}"*** *(1)*

Fehler: *Invalid Symbol, Unclosed stuff, overflow*

4. RECURS. DESCENT PARSER

Input: Tokens, ***Output:*** Syntaxbaum
Parser erkennt, ob Eingabetext den ***Syntax*** erfüllt. Funktioniert mit ***kontextfreien Sprachen*** *(als EBNF ausdrückbar + Stack)*. ***Concrete Syntax Tree*** *(Parse Tree)*: Vollständige Ableitung, erleichtert Parsen. ***Abstract Syntax Tree:*** Minimale Ableitung.

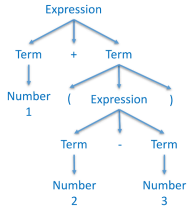

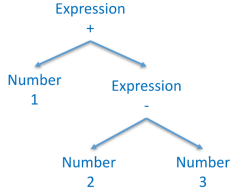

Parser-Klassen

- ***L*** für von links, ***R*** für von rechts
- ***L*** für Top down, ***R*** für Bottom up
- ***Zahl*** für Anzahl Token Lookahead

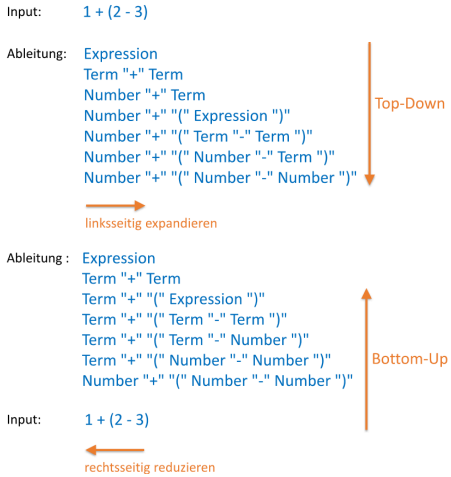

LR-Parser ist mächtiger als LL-Parser, kann Linksrekursion behandeln. E = [E] "x"

5. SEMANTISCHE ANALYSE

Syntaktisch ✓ ≠ Semantisch ✓
Input: Syntaxbaum, ***Output:*** Symboltabelle. Prüft, ob das Programm korrekt ist, ***kontextsensitive Grammatik*** *(Designators aufgelöst, alles deklariert, Typregeln erfüllt, Argumente und Parameter kompatibel, keine zyklische Vererbung, nur eine `main` Methode, …).*
Symboltabelle: Datenstruktur zur Verwaltung von Deklarationen.

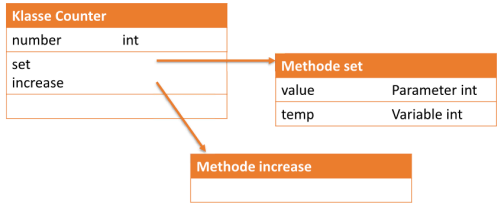


```
class Counter { int number;
  void set(int value) { int temp;
    temp = number; number = value; }
  void increase()
    { number = number + 1; } }
```

Shadowing: Deklaration innen verdecken gleichnamige äussere Scopes.
Global Scope: Enthält vordefinierte Typen, Konstanten, `this`, Built-in Methoden und `array.length`

6. CODE-GENERIERUNG

Input: Zwischendarstellung
Output: Ausführbarer Maschinencode
Visitor Pattern: Traversieren des AST pro Methode

```
while (x < 10) { x = x + 1; }
```

```
begin: load 1        ; Wert in x laden
       ldc 10        ; 10 laden
       icmplt        ; x < 10?
       if_false end  ; Condition check
       load 1        ; Wert in x laden
       ldc 1         ; 1 laden
       iadd          ; x + 1
       store 1       ; Resultat in x
       goto begin    ; Loop erneut
end:   ...           ; Loop beendet
```

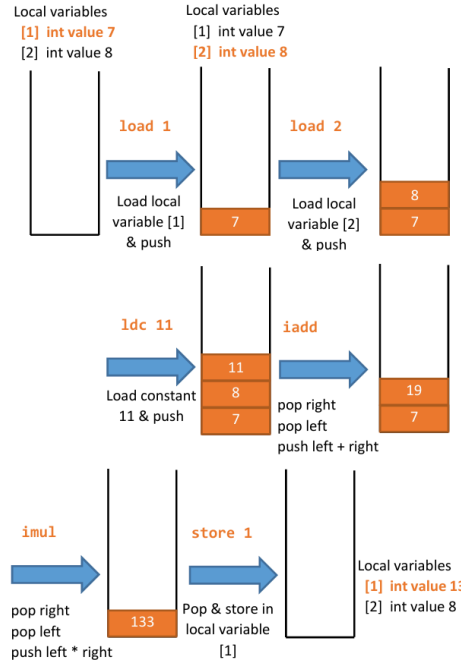

1. `this`-Referenz: Index 0
2. n Params: Index $1…n$
3. m lokale Variablen: Index $n+1…n+m$

7. CODE-OPTIMIERUNG

Arithmetik *(Zweierpotenzen in Bit-Operation umwandeln)*, ***Algebraisch*** *(Redundante Operatoren entfernen, konstante Literale zusammenfassen)*, ***Loop-Invariant Code Motion*** *(Unveränderter Code aus Schlaufe nehmen)*, ***Common Subexpressions*** *(Wiederholt ausgewertete Teilausdrücke zusammenfassen)*, ***Dead Code Elimination*** *(Nicht Verwendetes entfernen)*, ***Copy Propagation*** *(redundante `load` und `stores` entfernen)*, ***Constant Propagation*** *(konstante Variablen durch Konstante ersetzen)*, ***Partial Redundancy Elimination*** *(Expressions in Pfaden so wenig wie möglich evaluieren)*

Static Single Assignment (SSA): Variablen werden umbenannt, damit jede nur ein einziges Mal zugewiesen wird *(Veränderungen schnell erkennbar)*.

Bei Verzweigungen: φ(x1, x2)

Peephole Optimization: Sliding Window, Optimierungen werden auf diesen kleinen Bereich vorgenommen.

8. VIRTUAL MACHINE

Nützlich für ***Mehrplattformensupport***.

Loader: ***Liest Assembly*** und ***alloziert*** notwendige ***Laufzeitstrukturen***.

Kreiert Metadaten, initiiert Programmausführung.

Interpreter: Arbeitet mit einem ***Call Stack***, der aus ***Activation Frames*** besteht. Jeder ***Activation Frame*** verwaltet einen ***Evaluation Stack***.

Instruction Pointer: Adresse der nächsten Instruktion
(springt bei Branches <Zahl> + 1)

Evaluation Stack: Stack der Methode. *(item = register)*

Call Stack: Stack der ***Methodenaufrufe***. Verwaltet lokale Variablen und Rücksprungadresse *(item = activation frame)*

Managed *(mit Klassen modelliert)* ***Unmanaged*** *(Funktioniert mit Stack Pointer und Base Pointer)*

9. OBJEKT-ORIENTIERUNG

Heap: Objekte im Laufzeitsystem werden im Heap gespeichert *(Können nicht auf Stack gespeichert werden wegen nicht-hierarchischer Lifetime Dependency)*. Ist ein linearer Adressraum. ***Unabhängig*** vom Call Stack. Objekte werden immer durch eine ***Referenz*** verwiesen.

Objektblock: ***Mark Flag*** *(Für GC)*, ***Block Size*** *(Gesamtgrösse des Blocks)*, ***Type Tag*** *(Referenz zum Class Descriptor)*, ***Fields*** *(Inhalt des Blocks)*

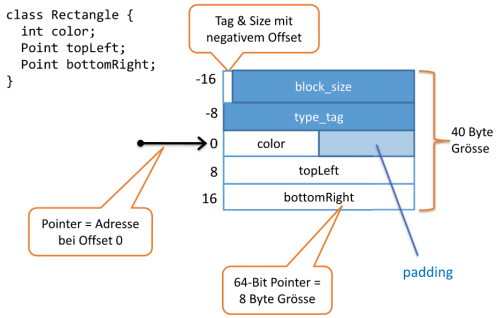

Typ-Polymorphismus: ***Subklasse*** erbt von und erweitert ***Basisklasse***. ***Downcasts*** müssen dynamisch überprüft werden.

Ancestor Tables: Jeder Class Descriptor hat eine *(Nur bei Single Inheritance)*.

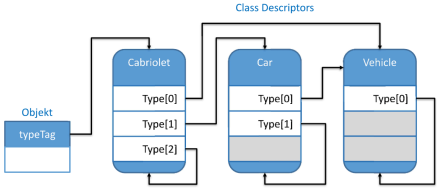

ancestor[i] = Zeiger auf Class Descriptor der Stufe i

Virtuelle Methoden: Methoden können ***überschrieben*** werden, Inhalt der bestehenden Methode wird ersetzt.

Virtual Method Table: Jeder ***Klassendeskriptor*** hat eine ***vTable*** mit den Methoden *(zu oberst von Basisklasse, bei Overriding wird nicht ersetzt, sondern ergänzt).*

Typdeskriptoren: Werden vom Loader generiert. Nützlich für Type Checking, Ancestor Table, vTables *(im Bild)*.

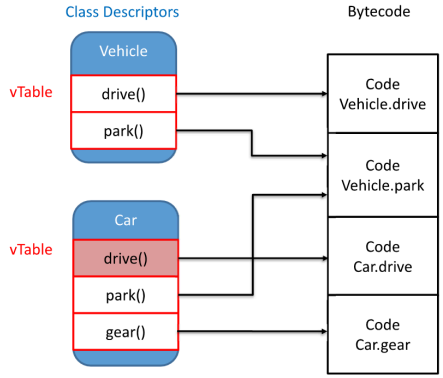

iTable: Global durchnummeriert, jede Methode hat in ihrer iTable an der Stelle Interfaces, wo sie sich auch in der globalen Tabelle befinden. Die Einträge verweisen auf vTables.

10. GARBAGE COLLECTION

Dangling Pointer: Referenz auf bereits gelöschtes Element

Memory Leak: Verwaiste Objekte

Garbage: Nicht mehr verwendete und erreichbare Objekte

Reference Counting: Counter pro Objekt mit eingehenden Referenzen *(Problematisch bei Zyklen)*.

Ablauf: ***Mark Phase*** *(Ausgehend vom Root Set (Call Stack) werden alle erreichbaren Objekte markiert)*

Sweep Phase *(Alle nicht markierten Objekte werden gelöscht)*

Free List: Liste der freien Blöcke, wird bei Allozierung traversiert. Nebeneinanderliegende freie Blöcke werden wieder verschmolzen.

Stop & Go: GC läuft ***sequenziell*** und ***exklusiv***. Mutator muss warten.
(Mark-Phase hätte Probleme bei Parallelität wegen Heap-Veränderungen, Sweep-Phase würde aber funktionieren.)

Compacting GC / Moving GC: Schiebt Objekte im Heap wieder zusammen. Der freie Speicher befindet sich zuhinterst im Heap. Referenzen müssen ***nachgetragen*** werden. ***Mark-Phase*** gleich wie bei Stop & Go, ***Sweep-Phase*** hätte dann der Mutator Zugriff auf verschobene Adressen. *(Vorteile: Eliminiert External Fragmentation, schnelle Speicherallozierung)*

11. JIT COMPILER

Profiling: Ausführung von Code-Teilen zählen, um ***Hot Spots*** *(oft ausgeführter Code)* zu erkennen.

Intel 64 Architektur: Instruktionen benutzen ***Register*** *(RSP: Stack Pointer, RBP: Base Pointer, RIP: Instruction Pointer)*

```
load 1 // x laden
ldc 1  // 1 laden
isub   // x - 1
ldc 3  // 3 laden
idiv   // RAX = (x - 1) / 3
# x64 Code: x sei in RAX
MOV RBX, 1    # 1 laden
SUB RAX, RBX  # RAX = x - 1
MOV RBX, 3    # 3 laden
CDQ           # RDX vorbereiten
IDIV RBX      # RAX = (x-1)/3
# Resultat ist in RAX
```

Lokale Register-Allokation: Jeder Eintrag des Evaluation Stack wird auf ein Register abgebildet.

Globale Register-Allokation: Zusätzlich auch lokale Variablen und Parameter.